

정확도를 넘어서: 의료 분야에서 대형 언어 모델의 추론 불일관성 측정

Beyond Accuracy: Measuring Reasoning Inconsistency of Large Language Models in Medical Domain

서원빈(Wonbin Seo)¹ 최동희(Donghee Choi)²

요약

의료 분야에서 LLM 활용이 확산됨에 따라 정확한 답변과 함께 신뢰할 수 있는 추론 근거가 요구되나, 현재의 정확도 중심 평가로는 추론 과정의 신뢰도를 포착하기 어렵다. 본 연구는 모델의 추론 흔적과 최종 답변 간 불일관성을 정량화하는 지표인 TIR(Trace Inconsistency Rate)을 의료 LLM 평가에 도입한다. 이를 위해 GPT-4o-mini와 Qwen-7B를 활용하여 MMLU-ProX 의료 문항(각 1,404개)과 USMLE 우울증 문항(각 270개)으로 다국어 벤치마크를 구성하고, LLM-as-a-Judge 기반 자동 평가 체계를 설계하였다.

실험 결과, 정확도와 TIR 사이에 강한 음의 상관관계가 확인되었으며(Pearson $r = -0.92$), 한국어 조건에서 추론 불일관성이 더 두드러지게 나타났다. 인간 평가와의 비교를 통해 자동 평가의 신뢰성을 검증하였으며(Cohen's $\kappa = 0.756$), 나아가 본 연구는 정답률을 넘어 추론 일관성이라는 기준을 도입하여 의료 분야의 LLM 평가의 방향성을 제시한다.

주제어: 언어 모델, 자연어 처리, 추론 평가, 우울증

1 부산대학교 정보컴퓨터공학부, 학사과정

2 부산대학교 정보컴퓨터공학부, 교수, 교신저자.

+ 본 연구는 2025학년도 부산대학교 교내학술연구비(신입교수연구정착금)에 의한 연구임. 본 연구는 과학기술정보통신부 및 정보통신기획평가원의 인공지능융합혁신인재양성사업 연구 결과로 수행되었음(IIIP-2026-RS-2023-00254177)

+ 논문접수: 2026년 07월 20일, 최종 심사완료: 2026년 08월 07일, 게재승인: 2026년 08월 19일.

Abstract

As LLMs expand into clinical decision support, reliable reasoning is as critical as accurate answers, yet current accuracy-based evaluation cannot capture reasoning reliability. This study introduces the Trace Inconsistency Rate (TIR), a metric quantifying discrepancies between a model's reasoning trace and its final answer, to evaluate medical LLMs. Using GPT-4o-mini and Qwen-7B, we constructed a multilingual benchmark from MMLU-ProX medical items (1,404 each) and USMLE depression questions (270 each), and built an LLM-as-a-Judge evaluation pipeline.

Results show a strong negative correlation between accuracy and TIR (Pearson $r = -0.92$), with reasoning inconsistency more pronounced in Korean conditions. Human evaluation confirmed the reliability of the automated pipeline (Cohen's $\kappa = 0.756$), and this work advances LLM evaluation in the medical domain by introducing reasoning consistency as a complementary assessment criterion beyond accuracy.

Keywords: Language Model, NLP(Natural Language Processing), Reasoning&Evaluation, Major Depressive Disorder

1. 서론

의료 데이터의 증가[1]와 복잡한 지식 체계 속에서 대형언어모델 (Large Language Models; LLM)은 방대한 의학 지식을 처리할 수 있는 기술적 도구로 주목 받고 있다. LLM은 의학 문헌과 임상 가이드라인을 학습하여 다양한 의료 관련 질의에 활용될 수 있는 기술적 대안으로 논의되고 있다[2].

LLM의 활용 가능성은 단순히 학습된 정보를 인출하는 능력을 넘어, 복잡한 문제에 대해 단계적으로 추론하는 능력에서도 나타난다[3]. 모델이 문제 해결 과정에서 명시적인 사고 단계를 거치는 것은 모델의 판단 과정을 관찰 가능하게 한다는 점에서도 의의가 있다[4]. 그러나 이러한 추론 능력을 정확히 측정하기 위해서는 단순 정확도를 넘어선 정밀한 평가 지표에 대한 논의가 필요하다.

의료 분야에서 LLM의 추론 능력은 단순한 기술적 성능을 넘어, 임상적 신뢰성의 문제와 직결된다. 논리적 일관성 없이 결론에 도달하는 모델은 정답을 맞히더라도, 잘못된 근거에 기반한 판단을 내릴 위험이 있다[5]. 이러한 문제는 증상의 경계가 불분명하고 임상적 맥락 이해가 필수적인 정신건강 영역, 특히 우울증 진단에서 더욱 두드러진다[6]. 동일한 임상 정보도 추론 방식에 따라 전혀 다른 결론으로 이어질 수 있기 때문이다.

그러나 현재의 LLM 평가는 정답 여부 중심의 정확도(Accuracy) 지표에 의존하며[7], 모델이 어떠한 추론 경로를 거쳐 결론에 도달했는지를 체계적으로 측정하는 시도는 충분히 이루어지지 않았다. 추론이 최종 답변과 일관되게 연결되는지를 검증하는 자동화된 평가 프레임워크 또한 의료 분야에서 본격

적으로 탐색 된 바 없다.


본 연구는 이러한 공백을 메우기 위해, TIR(Trace Inconsistency Rate) 지표를 의료분야의 LLM 평가에 도입했다. TIR은 모델의 추론과 최종 답변 간 불일관성을 정량화하는 지표로, 기존 정확도 평가가 설명하지 못하는 추론 과정의 신뢰도를 측정한다. 이를 위해 MMLU-ProX[8](영·한 각 1,404개)와 USMLE[9] 우울증 문항(영·한 각 270개)을 포함한 다국어 의료 벤치마크 데이터셋을 구성하고, LLM-as-a-Judge[10] 기반 자동 평가와 인간 검증을 결합한 평가 체계를 설계하였다.

본 연구의 주요 기여는 세 가지이다. 첫째, TIR 지표를 의료 분야의 LLM 평가에 도입하여 추론 불일관성을 정량적으로 측정하는 평가 체계를 제시한다. 둘째, 영어·한국어 총 3,348개 문항으로 구성된 다국어 의료 벤치마크를 구축하여 언어 의존적 추론 특성을 비교 분석한다. 셋째, 22개 문항에 대한 인간 평가자 gold standard를 구축하고(Cohen's $\kappa = 0.756$), AI 자동 평가의 신뢰도를 실증적으로 검증한다.

2. 관련 연구

2.1 의료 분야에서의 언어 모델

최근 LLM은 자연어 처리 분야를 넘어 전문 지식이 요구되는 의료 및 보건 데이터 분석에서도 그 성능을 보여주고 있다. 초기 연구에서 GPT-3와 같은 범용 모델이 미국 의사 면허 시험(USMLE) 등에서 합격선을 상회하는 점수를 기록하며 그 잠재력을 입증했다[11]. 그러나 의료 데이터 특유의 임상적 문맥의 복잡성, 생명과 직결되는 높은 신뢰도 요구 사항으로 인해 범용 모델만으로는 한계가 명확



[그림 1] 의료분야에서 LLM 추론 불일관성 측정을 위한 전체 연구 프레임워크

해졌다[12]. 이후 BioBERT 등 방대한 의학 문헌 및 임상 데이터를 활용한 도메인 특화 사전학습 및 미세 조정 모델들이 비약적인 발전을 이루었다[13]. 그러나 GPT-4와 같은 파라미터 규모가 거대한 생성형 LLM이 등장함에 따라, 의료 질의응답, 진단 보조, 환자 요약 등 보다 복잡한 태스크에서의 활용 가능성이 입증되었다[14]. 하지만 실제 임상 현장에서 요구되는 심층적인 인지과정이나 구문적, 증상적 분석이 중요시 되는 상황을 모사하는데는 한계를 보이고 있다[12].

2.2 언어 모델의 의학 추론

의학 분야에서의 의사결정은 환자의 다양한 증상, 병력, 검사 결과 등을 종합하여 가설을 설정하고 검증하는 고도의 임상 추론 과정이다[15]. 따라서 LLM이 실제 임상 전문가와 같은 수준의 신뢰성을 확보하기 위해서는 단순한 정보의 나열, 수치 분석을 넘어 결론에 도달하기까지의 명확한 논리적 근거와 일관성 있는 추론을 제시할 수 있는 능력이 필수적이다. 특히 LLM이 사실이 아닌 내용을 생성하는 환각 현상과 환자의 증상 묘사나 나이 등 구문적

인 상황 이해 부족은 환자의 생명과 직결되는 치명적인 오류를 범할 수 있으므로[16], 모델의 출력 결과에 따라 설명 가능성과 논리적 투명성을 보장하기 위한 추론의 중요성이 그 어느 때보다 대두되고 있다. LLM의 추론 능력을 극대화하고 내재된 한계를 극복하기 위해 최근 다양한 프롬프팅 및 구조적인 방법론들이 활발히 연구 되고 있다. 가장 대표적인 방법인 CoT(Chain of Thought)는 복잡한 문제를 중간 추론 단계로 분해[4]하여 LLM이 단계별 논리 전개를 수행하도록 유도함으로써, 의학 질의응답에서 모델의 성능이 비약적으로 향상했다. 이를 확장하여 여러 추론 경로를 탐색하고 검증하는 Tree of Thoughts(ToT)[17]을 적용하여 다수의 추론 결과 중 가장 신뢰할 수 있는 답을 도출하는 기법 등도 의학 진단 시나리오에 성공적으로 적용될 가능성이 있다[18].

2.3 언어 모델의 자동화 평가

언어 모델의 평가는 언어 모델의 성능 향상만큼 중요하다. 초기에는 객관식 벤치마크를 통해 모델의 지식, 상식, 추론 능력을 빠르고 객관적으로 측정하

는 방식이 주를 이뤘다[19]. 그러나 이러한 정확도 중심 평가는 정답 여부만을 측정할 뿐, 실제 사용자가 선호하는 응답의 질을 반영하지 못한다는 한계가 있다[10]. 이를 보완하기 위해 인간 기반 평가가 도입되었으며, 실제 사용자의 선호도를 Gold Standard로 삼아 응답 품질을 직접 평가한다[20]. 그러나 인간 평가는 비용과 시간이 많이 들고, 재현성이 떨어지며 평가자 개인의 편향이 개입된다[21]. 이러한 한계를 극복하기 위해 LLM-as-a-Judge[10]가 등장하였다. 이 방법은 강력한 대형 언어 모델을 심판으로 활용하여 높은 비용 문제를 해결하면서도, 프롬프트를 통해 평가 기준을 제시하고 모델 간 답변을 비교하거나 점수를 부여하는 방식으로 유연하게 적용된다. 나아가 모델의 추론 과정에 대한 정량적 평가까지 자동화할 수 있다면, 보다 신뢰할 수 있는 모델 선별이 가능해질 것으로 기대된다.

3. 방법론

3.1 예비 연구

평가 데이터셋 D 를 아래의 식과 같이 정의하자.

$$D = \{(x_i, y_i^*)\}_{i=1}^N$$

여기서 x_i 는 i 번째 문항, y_i^* 는 정답이다. 언어 모델 M 은 각 문항 x_i 에 대해 추론 과정 $\hat{r}_i$ 와 최종 답변 $\hat{y}_i$ 를 생성한다. 이때 두 이진 지표 변수를 다음과 같이 정의 한다.

$$a_i = 1[y_i = y_i^*] \in \{0, 1\} \text{ (정답 여부)}$$

$s_i \in \{0, 1\}$ (추론 일관성: s_i 가 1이면 $\hat{r}_i$ 가 $\hat{y}_i$ 를 논리적으로 지지).

이를 바탕으로 케이스 레이블 c_i 를 다음과 같이 정의한다.

$$c_i = 2(1 - a_i) + (1 - s_i) + 1 \in \{1, 2, 3, 4\}$$

각 케이스 별 문항 수는 $n_k = \sum_{i=1}^N 1[c_i = k]$ 이다.

자동화 분류 평가에서의 주요 평가 지표는 다음과 같다.

$$(1) \text{ Accuracy} = \frac{1}{N} \sum_{i=1}^N a_i = \frac{n_1 + n_2}{N}$$

$$(2) \text{ TIR} = \frac{1}{N} \sum_{i=1}^N (1 - s_i) = \frac{n_2 + n_4}{N}$$

TIR은 0에서 1(0%~100%) 사이의 값을 가지며, 값이 낮을수록 모델의 추론이 최종 답변과 일관되게 연결됨을 의미하고, 높을수록 모델이 추론 과정과 무관하게 답변을 생성하는 경향이 강함을 나타낸다. 예를 들어 TIR이 0에 가깝다면 모델은 제시한 추론 근거에 따라 일관되게 답변하고 있음을 뜻하며, TIR이 높다면 정답 여부와 무관하게 추론과 답변 사이에 단절이 빈번하게 발생하고 있음을 의미한다. 특히 정확도(Accuracy)가 높으면서 TIR도 높은 경우, 모델이 올바른 추론 없이 정답을 맞히는 추론 신뢰도가 낮은 상태임을 시사한다.

3.2 대형 언어 모델의 자동화 분류 평가

이 논문은 3-way 평가 방법을 취한다. 그중 하나는 시험지에서 언어 모델이 선택한 답과 정답지에 적혀있는 정답을 비교함으로써 정확도에 대한 채점을 시행하고 정답의 여부와 상관없이 언어 모델의

추론이 논리적으로 일관되게 결론에 도달하였는지, 추론 과정에서 사실관계 오류나, 논리 단절, 지문에 주어진 구문적 정보들을 놓치지 않았는지 평가한다. 자동화 케이스 분류는 비용 효율성을 고려하여 GPT-4o-mini를 사용하였으며, 분류 결과의 신뢰성 검증을 위한 인간 평가 비교(4.1절)에는 GPT-4o를 활용하였다. TIR(Trace Inconsistency Rate)은 모델의 추론 흔적과 최종 답변 간 불일관성을 정량화하는 지표로[7], 본 연구는 이를 의료 분야의 LLM 평가에 적용하였다. 마지막으로 문체 중 일부를 사람과의 평가 분석과 대화 모델의 평가 분석을 비교하여, 어떤 부분에서 대화 모델의 추론 오류 그리고 평가 오류가 드러나는지 평가한다.

이 논문에서 주장하는 TIR은 정답 여부와 상관없이 추론이 일관되게 결론에 도달했는지를 따지는 지표이다. TIR을 통해서 정확도와 추론 일관성에 따라 답변을 분류한다.

[표1] : Case taxonomy Table

Case	정답 일치	추론 일관성	TIR
Case CC	Correct (✓)	Consistent (✓)	
Case CI	Correct (✓)	Inconsistent (✗)	●
Case IC	Incorrect (✗)	Consistent (✓)	
Case II	Incorrect (✗)	Inconsistent (✗)	●

*First letter: C(Correct) / I(Incorrect) —

Answer Match

*Second letter: C(Consistent) / I(Inconsistent)

— Reasoning Consistency

· Case CC(1) : 정답이 일치하고 추론에 결함이 없음.

· Case CI(2) : 정답이 일치하고 추론에 의학적 오류나 논리적 비약이 있음.(TIR Match)

· Case IC(3) : 정답이 일치하지 않고, 추론이 모델의 오답을 일관되게 지지함.

· Case II(4) : 정답이 일치하지 않고, 추론이 모

델의 예측을 제대로 설명하지 못함. (TIR Match)

TIR의 핵심은 추론을 정답 도출을 위한 종속적 수단이 아닌, 독립적 평가 지표로 본다는 것이다. 이 자동화된 채점 프레임워크에서 가지는 특징은 추론을 결론과 독립시켜 추론 그 자체가 가지는 오류는 없는지, 추론 안에서의 논리적 단절이 없는지 검증하는 것이다. 이런 프레임워크는 단순히 높은 정확도를 주장하는 여러 대화 모델 사이에서 어느 모델이 정말 신뢰할 수 있는 모델인지 판단할 수 있게 한다. 그리고 대화 모델이 채점한 것을 바탕으로 정확히 채점하고 Case 분류를 하였는지 확인하기 위해 사람이 마지막으로 한 번 더 검증한다. 사람의 검증은 정답 일치와 추론 일관성 채점을 넘어, 모델의 추론 오류 유형과 AI 평가자의 채점 오류 패턴을 분석하는 것을 포함한다. 이를 통해 자동화 평가 체계의 신뢰성을 실증적으로 검토한다.

3.3 실험 설정

3.3.1 데이터셋 설정

실험에 사용한 데이터셋은 아래와 같다.

— MMLU-ProX[8]: 기존 MMLU-Pro 데이터셋을 다국어로 확장한 벤치마크이다. 의학 분야 문항을 대상으로 영어 및 한국어 각 1404개, 총 2808개의 문항을 활용하였으며, 다양한 임상 추론 능력을 요구하는 문항으로 구성되어있다.

— 미국 의사 면허시험 데이터셋(USMLE)[9]: 미국 의사 면허 시험 문항 데이터베이스에서 우울증 관련 키워드를 기준으로 추출한 문항들로 구성된다. 전체 4천여 개의 문항 중 우울증과 직접적으로 관련

된 문항 270개를 선별하여 영어 및 한국어 각 270개, 총 540여개의 문항을 실험에 사용하였다.

미국 의사 면허 시험 데이터셋에서는 우울증과 관련한 키워드를 지정하여, 그 샘플링한 단어가 선지나 지문에 포함된 문제 270개를 표본을 추출했다. 우울증은 명확한 생체지표 없이 환자의 증상 호소에 의존하는 질환으로, 타 정신질환과의 감별 진단이 요구되며 임상적 판단의 모호성이 높다[22]. 이러한 특성으로 인해 대화 모델의 정밀한 추론 능력을 평가하기에 적합한 질병이다. 또한 모델이 추론 시 어느 단서에 집중하고 어느 지점에서 오류를 범하는지를 직접적으로 분석할 수 있다. 우울증 관련 문항의 임상적 타당성과 포괄적 적용 범위를 동시에 확보하기 위해, 키워드 선정은 확립된 임상 기준에 근거한 2단계 체계를 따랐다. 1단계는 DSM-5(Diagnostic and Statistical Manual of Mental Disorders, Fifth Edition)의 주요우울장애 진단 기준에 직접적으로 대응하는 진단 용어(depression, depressive)로 구성하였다[22]. 2단계는 미국 정신의학회의 임상 가이드라인에서 우울증 1차 치료제로 권고하는 약물 분류명(SSRI, antidepressant)을 포함하였다[23]. 이러한 계층적 접근 방식은 우울증 관련 문항의 재현율을 극대화하는 동시에, 관련성이 낮은 문항의 포함을 최소화하기 위해 설계되었다. 시험지는 문제, 선지, 정답을 적는 곳, 추론을 적는 곳, 정답 일치 여부 적는 곳, Case 분류한 것을 적을 수 있는 곳으로 구성된다. 문제를 풀게 할 때는 문제와 선지를 보고 정답을 적는 곳에 알파벳 형태(e.g., "A") 형태로 답을 적고 통제된 추론 풀이 방법에 따른 풀이를, 추론을 적는 곳에 표기한다. 또한 평가 시 추론 오류의 원인을 구체적으로 분석하기 위해, 모델이 문제 풀이 과정에서

발생시키는 오류를 의학적 사실 오류, 논리적 단절, 정보 간과 및 오해, 모호한 응답의 네 가지 유형으로 분류하였다.

- **의학적 사실 오류(Medical Fact Error)** : 모델이 확립된 임상 지침이나 의학적 사실에 반하는 잘못된 정보를 제공하거나 지식 자체를 왜곡하여 제시하는 경우
- **논리적 단절(Logical Disconnection)** : 추론 과정에서 전제와 결론 사이에 논리적 연결이 끊기거나, 앞뒤 문맥이 맞지 않는 논리적 비약이 발생하는 경우
- **정보 간과 및 오해(Information Oversight)** : 문제에서 제시된 중요한 임상적 단서나 제약 조건을 빠뜨리거나, 주어진 선택지의 의미를 잘못 해석하여 판단 근거에서 제외하는 경우
- **모호한 응답(Ambiguous Response)** : 추론 내용이 불분명하거나 상충하는 설명을 포함하여, 최종 선택한 정답에 대해 명확하고 일관된 근거를 제시하지 못하는 경우

3.3.2 모델과 프롬프팅

문제를 풀 때는 GPT-4o-Mini, Qwen2.5-7B-Instruct-Turbo를 사용하였다. 채점과 추론 일치도 분류는 GPT-4o Mini를, 추론 분석을 할 때는 GPT-4o를 사용하였다. 문제를 풀게 할 때는 페르소나 프롬프팅을 통해서 모델에게 현재 상황을 알려주고 어떤 방법으로 문제를 풀어야 하는가, 어떤 형식으로 답과 추론을 표기해야 하는지 고지했다. 방법은 CoT(Chain of Thought)와 SoT(Skeleton of Thought)[24]를 사용하였고 이 또한 프롬프트를 통해 해당 방법을 정의하고 설명된 방법에 따라 추론하고 문제를 풀 것을 지시하였다. CoT방법은 대형 언어 모델이 복잡한 추론 문제를 해결할 때, 최종 정답에 도달하기 전 중간 단계의 논리적 추론 과정을

명시적으로 생성하도록 유도하는 프롬프팅 기법이다. SoT 방법은 추론의 효율성과 구조화를 극대화하기 위해 제안된 기법으로 먼저 전체적인 답변의 골격을 생성한 뒤, 각 하위 요소를 병렬적으로 구체화하는 방식이다. 단, USMLE 우울증 데이터셋은 인간 평가자의 추론 방식과 직접 비교하기 위해 C

oT 방법론만 적용하였다. 이 두 방법의 프롬프트를 표 2에 명시한다. 채점할 때는 대화 모델에게 역할을 고지하고, 해야 하는 것들을 지시하고 추가로 하지 않아야 할 것들을 페르소나 프롬프팅을 통해 자세히 명확하게 통제했다.

[표2]. 모델 추론과 평가에 사용된 페르소나 프롬프트

Category	System Persona & Configuration Detail
Persona(CoT)	You are a medical education expert and an examination board member. This task is for generating educational data for medical competency assessment and is NOT intended for actual clinical diagnosis. When solving the provided problem, strictly follow the CoT (Chain-of-Thought) approach: [Reasoning]: - Analyze the patient's condition, medical history, and lab results from an educational perspective. - Provide a step-by-step reasoning for why each option is either correct or incorrect based on medical evidence.
Persona(SoT)	[Skeleton Phase] - List the core medical concepts and a step-by-step verification plan for options [Expansion Phase] - Provide a detailed medical analysis for each option based on the skeleton plan. [Final Conclusion] - Provide ONLY the single capital letter of the correct answer, e.g., A
Evaluation	[Tasks] 1. Accuracy Evaluation: Compare the 'answer' from ground_truth with the model's 'predicted_answer'. If they match, set is_correct to true; otherwise, false. 2. GPT-4o-miniTIR & Case Analysis: Analyze the generated_trace according to the criteria below and write the case number in the case_label field as "Case_Number". [Case Criteria] - Case_1 (C&C): Correct answer, and the trace logically supports it. - Case_2 (C&I): Correct answer, but the trace is invalid or inconclusive (lucky guess). -> TIR Detected - Case_3 (I&C): Incorrect answer, and the trace logically supports that incorrect conclusion. - Case_4 (I&I): Incorrect answer, and the trace is logically collapsed or inconclusive. -> TIR Detected

[표3]. 데이터셋·모델·방법론·언어별 정확도, TIR 비교(%)

Dataset	Model	Method	Lang	N	Acc (%)	TIR (%)
MMLU-ProX	GPT-4o-mini	CoT	EN	1404	68.95	12.75
MMLU-ProX	GPT-4o-mini	CoT	KO	1404	62.33	36.61
MMLU-ProX	GPT-4o-mini	SoT	EN	1404	71.30	12.75
MMLU-ProX	GPT-4o-mini	SoT	KO	1404	58.26	40.46
MMLU-ProX	Qwen-7B	CoT	EN	1404	62.39	9.40
MMLU-ProX	Qwen-7B	CoT	KO	1404	44.58	52.56
MMLU-ProX	Qwen-7B	SoT	EN	1404	59.90	19.16
MMLU-ProX	Qwen-7B	SoT	KO	1404	43.52	54.91
USMLE	GPT-4o-mini	CoT	EN	270	72.86	7.06
USMLE	GPT-4o-mini	CoT	KO	270	58.52	21.85
USMLE	Qwen-7B	CoT	EN	270	51.11	37.41
USMLE	Qwen-7B	CoT	KO	270	37.41	61.48

*용어: Lang: Language, EN: English, KO: Korean, CoT: Chain of Thought, SoT: Skeleton of Thought, N: 데이터셋 수, ACC: Accuracy

4. 실험 결과

표 3에 의하면 MMLU-proX에서 GPT-4o-mini는 CoT와 SoT를 비교했을 때, 68.95%(CoT)에서 71.30%(SoT)로 소폭 상승하였고, Qwen-7B는 62.39%(CoT)에서 59.90%(SoT)로 소폭 하락하였다. 반면 한국어 지문과 프롬프트로 문제가 주어졌을 때에는, GPT-4o-mini의 경우 62.3%(CoT)에서 58.3%(SoT)로 소폭 하락하였으며, Qwen-7B의 경우 CoT로 풀게 했을 때(44.59%)보다 SoT로 풀었을 때(43.52%)로 정확도가 소폭 하락하였으며, TIR 또한 상승하였다. 미국 의사 면허 시험 데이터셋에서는 영어로 풀게 했을 때 GPT-4o-mini의 경우 정확도가 72.85%, 한국어로 풀게 했을 때의 정확도가 58.51%로 집계됐으며, Qwen-7B의 경우 영어로 풀

었을 때 51.11%, 한국어로 풀었을 때 37.41%로 하락했다. 두 모델 모두 영어보다 한국어에서 더 높은 TIR 비율이 나왔다. 푸는 문제에 대한 각각의 TIR 지표 유형 분포율은 표4에 명시한다. 전반적으로 한국어 데이터셋에 대해서는 Case II의 비율이 많았고 영어 데이터셋에 대해서는 Case IC의 비율이 오류의 중심을 차지했다.

[표4] 데이터셋·모델·방법론·언어별 추론 일관성 유형 분포율(%)

Dataset	Model	Method	Lang	CC (%)	CI (%)	IC (%)	II (%)
MMLU-ProX	GPT-4o-mini	CoT	EN	68.52	0.43	18.73	12.32
MMLU-ProX	GPT-4o-mini	CoT	KO	61.97	0.36	1.42	36.25
MMLU-ProX	GPT-4o-mini	SoT	EN	70.73	0.57	16.52	12.18
MMLU-ProX	GPT-4o-mini	SoT	KO	58.05	0.21	1.50	40.24
MMLU-ProX	Qwen-7B	CoT	EN	62.18	0.21	28.42	9.19
MMLU-ProX	Qwen-7B	CoT	KO	44.16	0.42	3.28	52.14
MMLU-ProX	Qwen-7B	SoT	EN	59.33	0.57	21.51	18.59
MMLU-ProX	Qwen-7B	SoT	KO	43.52	0.00	1.57	54.91
USMLE	GPT-4o-mini	CoT	EN	68.40	4.46	24.54	2.60
USMLE	GPT-4o-mini	CoT	KO	52.59	5.93	25.55	15.93
USMLE	Qwen-7B	CoT	EN	51.11	0.00	11.48	37.41
USMLE	Qwen-7B	CoT	KO	37.41	0.00	1.11	61.48

*First Letter C/I: Correct/Incorrect, *Second Letter C/I: Consistent/InConsistent

4.1 인간 평가 대비 자동 케이스 분류 정확도 검증

TIR지표의 타당성을 검증하기 위해, GPT-4o-mini 기반 자동 케이스 분류 결과를 사람의 평가와 비교하였다. 검증 대상 문항은 모두 영어로 구성되었으며, 이는 평가자의 한국어 언어 처리 한계가 케이스 분류 결과에 개입될 가능성을 통제하기 위한 선택이다. 검증 데이터셋으로 USMLE 우울증 문항을 선택한 것은, MMLU-ProX가 단편적 지식 확인 형태의 문항 위주인 반면, USMLE 우울증 문항은 복합적인 임상 맥락을 단계적으로 분석해야 하는 특성상 추론 일관성 평가의 변별력이 더 높다고 판단하였기 때문이다. 이러한 특성이 추론 일관성 평가의 변별력을 높인다고 판단하였다. USMLE 우울증 데이터셋에서 무작위 표집한 22개 문항을 대상으로 인간 평가자가 직접 케이스 레이블을 부여하고, 이

를 AI 분류 결과와 대조하여 분석한다. 표 5는 AI 평가자와 인간 평가자 간의 케이스 분류 일치도를 Cohen's κ 및 Agreement(%)로 제시한다. 4-class 케이스 분류에서 $\kappa = 0.756$, 일치율 81.8%로 실질적 수준의 일치(Landis & Koch, 1977)를 보였으며, TIR 탐지(이진 분류) 기준에서도 $\kappa = 0.621$, 일치율 81.8%로 유사한 수준을 나타냈다. 불일치 사례 4건은 모두 AI 평가자가 Case II(오답·불일관)를 Case IC(오답·일관)로 오분류한 경우로, 추론 불일관성 탐지에서 AI 평가자의 체계적 편향이 확인되었다. 이는 자동화 평가만으로는 TIR 케이스를 완전히 포착하기 어려우며, 인간 검증을 통한 보완이 필요함을 시사한다.

[표5]. AI-인간 케이스 분류 일치도

평가 항목	Cohen's κ	Agreement (%)
4-Class 케이스 분류	0.756	81.8%
TIR 탐지(이진 분류)	0.621	81.8%

* N=22 (인간 평가자 표집). κ : Cohen's Kappa (0.61-0.80 = 실질적 일치, Landis & Koch, 1977)

4.2 TIR 지표를 통한 추론 일관성 경향 분석

GPT-4o-mini 기반 케이스 분류 결과를 토대로 모델 및 데이터셋 전반의 TIR 경향을 분석하였다. 정확도와 TIR 사이에는 강한 음의 상관관계가 확인되었다(Pearson $r = -0.92$). 이는 정확도가 낮은 조건일수록 추론 불일관성이 높아지는 경향이 있음을 의미하며, TIR 상승은 주로 Case II에 의해 구성되는 것으로 나타났다. 즉, 모델이 오답에 도달할 때 추론의 일관성 또한 함께 저하되는 경향이 있음을 시사한다. 이를 오류 구성 비율로 살펴보면, 한국어 조건에서는 TIR(Case CI+II)이 전체 오류(Case CI+IC+II)의 94~98%를 차지하여 정확도 하락과 거의 동일한 정보를 담지만, 영어 조건에서는 22~40%에 그쳐 Case IC(오답·일관 추론)이 오류의 상당 부분을 구성한다. 이는 TIR의 판별력이 언어 조건에 따라 달라짐을 의미하며, 특히 영어 조건에서 TIR이 정확도와 독립적인 추론 신뢰도 정보를 제공하는 보완적 지표로서의 가치가 두드러짐을 시사한다.

정성적 분석을 병행한 결과, 오류가 집중된 문항에서 두 가지 경향이 확인되었다. 첫째, 의학적 개념 자체에 대한 이해는 양호하나 환자의 나이, 치료 이력, 임상 상황 등 구문적 맥락 정보를 복합적으로 고려해야 하는 문항에서 추론의 일관성이 저하되는 경향이 나타났다. 표 6의 사례에서 모델은 추론 과정에서 재발성 우울증(recurrent depression) 병력을 명시적으로 인지하였음에도, 재발 이력이 있는

환자에게 적용되는 장기 복용 기준(1~2년 이상) 대신 초발 우울증에 준하는 일반 권고(6개월)를 최종 답변으로 선택하였다. 이는 지문 내 핵심 임상 정보를 추론 과정에서 충분히 반영하지 못하는 정보 간과(information oversight)에 해당한다. 둘째, 부정형(negative format)으로 구성된 문항에서 모델이 긍정형으로 해석하여 추론을 전개하는 사례가 관찰되었으며, 이는 Case CI 및 Case II 발생과 연관된다. 표 7의 사례에서 모델은 "가장 미성숙한(immature) 방어기제"를 묻는 질문을 "가장 적절한 방어기제"로 잘못 해석하여 추론을 전개하였다. 추론 과정에서 splitting을 올바르게 식별하였으나 'immature'라는 핵심 조건을 간과함으로써, 정답과 동일한 답변을 선택하였음에도 추론이 질문 의도와 일치하지 않는 Case CI로 분류되었다. 이러한 결과는 TIR이 정확도와 독립적으로 추론 과정의 취약 지점을 정량화할 수 있음을 보여주며, 의료 분야에서 대화 모델의 자동화된 추론 검증 가능성을 정량·정성적으로 뒷받침한다. 표 6은 복잡한 임상적 맥락에서 모델이 상황을 충분히 파악하지 못한 채 답변을 생성한 사례를, 표 7은 부정형 질문 포맷에서 발생하는 추론 불일관성 사례를 제시한다.

[표6] 구문적 상황 파악 능력 부족의 예시

Audit Sample #9 ID: 678 Case IC
A 27-year-old man comes to the physician for a follow-up examination. Paroxetine therapy was initiated 6 weeks ago for a major depressive episode. He now feels much better and says he is delighted with his newfound energy. He gets around 8 hours of sleep nightly. His appetite has increased. Last year, he had <u>two episodes of depressed mood, insomnia, and low energy during which he had interrupted his job training and stopped going to the gym</u>. Now, he has been able to resume his job at a local bank. He also goes to the gym three times a week to work out and enjoys reading books again. His temperature is 36.5°C (97.7°F), pulse is 70/min, and blood pressure is 128/66 mm Hg. Physical and neurologic examinations show no abnormalities. On mental status examination, he describes his mood as ""good." Which of the following is the most appropriate next step in management?"
Options
{'A': 'Continue paroxetine therapy for 2 years', 'B': 'Discontinue paroxetine', 'C': 'Continue paroxetine therapy for 6 months', 'D': 'Switch from paroxetine to lithium therapy'}
Gold standard : A , AI_Ans : C
AI Reasoning(Korean Translation)
환자는 6주간의 paroxetine 치료 후 우울 증상에서 유의미한 호전을 보였다. 재발성 우울 삽화 병력이 있다는 점에서 재발 방지를 위한 치료 지속이 중요하다. 항우울제에 양호한 반응을 보인 환자에 대한 표준 권고에 관해 달성 후 최소 6개월간 약물을 지속하여 치료 효과를 공고히 하고 재발 위험을 낮추는 것이다. 따라서 가장 적절한 다음 관리 단계는 paroxetine 치료를 6개월간 지속하는 것이다.

[표7] 부정형 질문 포맷에 대한 취약성

Audit Sample #21 ID: 1549 Case CI
A 31-year-old male comedian presents to your mental health clinic for a psychotherapy appointment. He is undergoing psychodynamic psychotherapy for depressive symptoms. During the therapy session, you discuss his job as a successful comedian and identify ways that he channels his emotions about his abusive childhood into comedy routines. Though <u>he enjoys his job overall and idolizes some of his coworkers, he complains about most of them being "totally incompetent."</u> When you attempt to shift the discussion back to his childhood, he avoids eye contact and <u>he tells you he "doesn't want to talk about it anymore."</u> Which of the <u>following</u> is an <u>immature defense mechanism</u> exhibited by this patient?
Options
{ 'A': 'Denial', 'B': 'Reaction formation', 'C': 'Splitting', 'D': 'Suppression' }
Gold standard : C , AI_Ans : C
AI Reasoning(Korean Translation)
환자는 동료들을 '완전히 무능하다'라고 보는 경향을 보이는데, 이는 흑백 논리적 사고 패턴을 반영한다. 이는 개인이 자신이나 타인의 긍정적·부정적 측면을 통합하지 못해 극단적 평가로 이어지는 분열(splitting)의 특징이다. 어린 시절에 대한 논의를 회피하는 것은 과거 감정을 화해시키지 못하는 이 방어기제를 더욱 뒷받침한다.

5. 결론

본 연구는 추론 일관성 지표인 TIR을 의료 분야에 도입하고, 대화 모델의 추론 과정을 4가지 케이스로 분류하는 평가 체계를 제안하였다. MMLU-ProX 및 USMLE 우울증 데이터셋을 대상으로 GPT-4o-mini와 Qwen-7B의 영어·한국어 추론 결과를 분석하였으며, 정확도만으로는 포착되지 않는 추론의 차이를 TIR을 통해 정량적으로 확인하였다.

이 연구의 주요 발견은 다음과 같다. 첫째, 높은 정확도에도 불구하고 유의미한 수준의 TIR이 관찰되어, 추론 불일관성이 정확도와 독립적으로 발생하며, 특히 오답 상황(Case II)에서 추론 일관성도 함께 저하되는 경향이 있음을 확인하였다. 둘째, 인간 평가자와의 비교에서 전체 일치율 81.8%를 달성하였으나, AI 평가자가 Case II를 Case IC로 잘못 분류하는 체계적 한계가 나타났다. 셋째, 정성 분석을 통해 구문적 맥락 이해 부족과 부정형 문항에서의 추론 오류가 TIR 상승의 주요 원인으로 확인되었다.

향후 연구에서는 더 많은 인간 평가자를 통한 교차 검증과 오류 유형의 분류를 통해 평가 체계의 신뢰도를 높이는 것이 필요하다. 나아가 본 연구는 정답·오답 일치 여부에 국한된 기존 자동 채점 방식을 넘어, 추론 과정 자체를 자동화된 지표로 평가할 가능성을 제시한다는 점에서 의의가 있다. 이는 단순 정확도 중심의 벤치마크 평가에서 추론 중심의 평가로 패러다임을 확장하는 미래 연구의 출발점이 될 수 있다.

6. 제한점

본 연구의 인간 평가는 소규모 표본(22개 문항)에 기반하여 수행하였으며, 향후 연구에서

MMLU-ProX를 포함한 확장 검증이 필요하다. 표본 수의 제약으로 인해 오류 유형별 경향을 통계적으로 일반화하기에는 충분하지 않으며, 관찰된 패턴은 예비적 수준의 분석으로 해석되어야 한다. 또한 인간 평가자가 단일 검증자로 구성되어 평가자 간 신뢰도를 산출하지 못하였다. 향후 연구에서는 표본 규모를 확대하고 복수의 전문가 평가자를 통한 교차 검증을 통해 본 평가 체계의 타당성을 보강할 필요가 있다. 마지막으로, 인간 검증이 영어 문항에 한정되어 수행되었으므로, 한국어 조건에서의 Case IC→Case II 패턴이 모델의 추론 실패에 기인하는지 평가자의 언어 처리 한계에 기인하는지는 본 연구에서 완전히 분리되지 않는다.

참고 문헌

- [1] Oakden-Rayner, Luke. "Exploring large-scale public medical image datasets." *Academic radiology* 27.1 (2020): 106-112.
- [2] Singhal, Karan, et al. "Large language models encode clinical knowledge." *Nature* 620.7972 (2023): 172-180.
- [3] Lievin, Valentin, et al. "Can Large Language Models Reason About Medical Questions?." *Patterns* 5.3 (2024).
- [4] Wei, Jason, et al. "Chain-of-thought prompting elicits reasoning in large language models." *Advances in neural information processing systems* 35 (2022): 24824-24837.
- [5] Turpin, Miles, et al. "Language models don't always

- say what they think: Unfaithful explanations in chain-of-thought prompting." *Advances in Neural Information Processing Systems* 36 (2023): 74952-74965.
- [6] Yang, Kailai, et al. "Towards interpretable mental health analysis with large language models." *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. 2023.
- [7] Ovalle, Anaelia, et al. "Beg to Differ: Understanding Reasoning-Answer Misalignment Across Languages." *arXiv preprint arXiv:2512.22712* (2025).
- [8] Xuan, Weihao, et al. "Mmlu-prox: A multilingual benchmark for advanced large language model evaluation." *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*. 2025.
- [9] Jin, Di, et al. "What disease does this patient have? a large-scale open domain question answering dataset from medical exams." *Applied Sciences* 11.14 (2021): 6421.
- [10] Gu, Jiawei, et al. "A survey on llm-as-a-judge." *The Innovation* 7.6 (2026).
- [11] Ahmed, Awais, et al. "MED-Prompt: A novel prompt engineering framework for medicine prediction on free-text clinical notes." *Journal of King Saud University-Computer and Information Sciences* 36.2 (2024): 101933.
- [12] Nori, Harsha, et al. "Capabilities of gpt-4 on medical challenge problems." *arXiv preprint arXiv:2303.13375* (2023).
- [13] Lee, Jinhyuk, et al. "BioBERT: a pre-trained biomedical language representation model for biomedical text mining." *Bioinformatics* 36.4 (2020): 1234-1240.
- [14] Nori, Harsha, et al. "Can generalist foundation models outcompete special-purpose tuning? case study in medicine." *arXiv preprint arXiv:2311.16452* (2023).
- [15] Kassirer, Jerome P. "Diagnostic reasoning." *Annals of internal medicine* 110.11 (1989): 893-900.
- [16] Pal, Ankit, Logesh Kumar Umapathi, and Malaikannan Sankarasubbu. "Med-halt: Medical domain hallucination test for large language models." *Proceedings of the 27th Conference on Computational Natural Language Learning (CoNLL)*. 2023.
- [17] Yao, Shunyu, et al. "Tree of thoughts: Deliberate problem solving with large language models." *Advances in neural information processing systems* 36 (2023): 11809-11822.
- [18] Peng, Qi, et al. "Tree-of-Reasoning: Towards Complex Medical Diagnosis via Multi-Agent Reasoning with Evidence Tree." *Proceedings of the 33rd ACM International Conference on Multimedia*. 2025.
- [19] Hendrycks, Dan, et al. "Measuring massive multitask language understanding." *arXiv preprint arXiv:2009.03300* (2020).
- [20] Tam, Thomas Yu Chow, et al. "A framework for human evaluation of large language models in healthcare derived from literature review." *NPJ digital medicine* 7.1 (2024): 258.
- [21] Clark, Elizabeth, et al. "All that's 'human' is not gold: Evaluating human evaluation of generated text." *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and*

the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). 2021.

- [22] Regier, Darrel A., Emily A. Kuhl, and David J. Kupfer. "The DSM-5: Classification and criteria changes." *World psychiatry* 12.2 (2013): 92-98.
- [23] Gelenberg, Alan J., et al. "American Psychiatric Association practice guidelines for the treatment of patients with major depressive disorder." *Am J Psychiatry* 167.Suppl 10 (2010): 9-118.
- [24] Ning, Xuefei, et al. "Skeleton-of-thought: Prompting llms for efficient parallel generation." *International Conference on Learning Representations*. Vol. 2024. 2024.

서 원 빈



2022년~현재 : 부산대학교 학사과정

관심분야 : LLM, NLP

E-mail : wbseo@pusan.ac.kr

최 동 희



2012년 고려대학교 컴퓨터통신공학
학사

2014년 고려대학교 바이오정보학협동
과정 석사

2023년 고려대학교 컴퓨터학과 박사

2024년~2025년 임페리얼칼리지런던 박사후 연구원

2025년~현재 부산대학교 정보컴퓨터공학부 조교수

관심분야 : 자연어처리, 데이터마이닝, 식품·의학·금융도
메인 AI

E-mail : dchoi@pusan.ac.kr